而且既然 dx^2 必然为正(因为任何平方均为正),可得:

$$f''(x) < 0 \tag{2.77}$$

这就是所求的二阶条件。换句话说,它要求函数在临界点是"凹"的(请对比图 2.1 和图 2.2),在本书后面我们将会遇到这一思想的推广。

2.8.2　二元函数

这里我们考虑第二种情况,即有两个独立变量的函数 y:

$$y = f(x_1, x_2) \tag{2.78}$$

我们已经知道这样的函数达到最大值的必要条件是函数对 x_1 与 x_2 的偏导数都是 0,即:

$$\begin{aligned} \frac{\partial y}{\partial x_1} &= f_1 = 0 \\ \frac{\partial y}{\partial x_2} &= f_2 = 0 \end{aligned} \tag{2.79}$$

满足(2.79)式的点为函数的"扁平"点($dy = 0$ 的点),可能是函数的最大值点。为确保此点是一局部最大值点,必然有由临界点向各个方向移动时 y 均递减。直观地看,只有确保不管向哪个方向走都是下坡路,才能说这点是"山顶"。

2.8.3　直观的讨论

之前我们描述了为何单一变量情形的简单一般化说明了对于局部最大值二阶自偏导数(f_{11} 与 f_{22})都必须是负的。在爬山的类比中,如果只考虑东西方向或者南北方向,在经过山顶时山峰的斜率一定递减,斜率一定由正变负。如果初始点并不是单纯地沿着 x_1 或者 x_2 的方向移动,而是两个变量一起变化的情形(如从东北方向向西南方向移动),则复杂性明显增加。此时,单纯的二阶偏导数不能提供关于临界点附近斜率变化的全部信息。只有加上交叉偏导数的条件($f_{12} = f_{21}$)才能保证由临界点向任何方向移动时 dy 都递减。正如我们将看到的那样,这些条件等价于要求函数的二阶自偏导数足够负以平衡任何可能的交叉偏导数的"异常"情形。直观地说,如果山峰在南北方向与东西方向都很陡,那么在其他方向相对小的坡度就可以被补偿以保证其总体仍是下坡。

2.8.4　正式的分析

现在我们对上述观点给出一个正式的表达。我们希望看到的是这些条件由函数 f 的二阶偏导数来表示,从而使得通过临界点向任何方向移动时 d^2y 均为负。首先,函数的全微分为:

$$dy = f_1 dx_1 + f_2 dx_2 \tag{2.80}$$

dy 的微分是:

$$d^2y = (f_{11} dx_1 + f_{12} dx_2) dx_1 + (f_{21} dx_1 + f_{22} dx_2) dx_2$$

或者

$$d^2y = f_{11} dx_1^2 + f_{12} dx_2 dx_1 + f_{21} dx_1 dx_2 + f_{22} dx_2^2$$

由杨氏定理,有 $f_{12} = f_{21}$,整理得:

$$d^2y = f_{11} dx_1^2 + 2f_{12} dx_1 dx_2 + f_{22} dx_2^2 \tag{2.81}$$

如果对 x 的任何变化(即任取 dx_1 与 dx_2)均有(2.81)式恒为负,则显然 f_{11} 与 f_{22} 均为负。例如,取 $dx_2 = 0$,则有:

$$d^2y = f_{11} dx_1^2 \tag{2.82}$$

$d^2y<0$ 意味着：

$$f_{11} < 0 \tag{2.83}$$

同样，由 $dx_1=0$，得到 $f_{22}<0$。如果 dx_1 和 dx_2 均不为0，则我们必须考虑用交叉二阶偏导数 f_{12} 来确定是否 d^2y 恒为负。应用简单的代数知识可知，此时要求的条件是[①]：

$$f_{11}f_{22} - f_{12}^2 > 0 \tag{2.84}$$

2.8.5　凹函数

直观来看，(2.84)式要求二阶自偏导数(f_{11} 和 f_{22})必须足够负，以使它们的乘积(为正)超过交叉偏导数($f_{12}=f_{21}$)。满足这样条件的函数被称为凹函数(concave function)。这样的函数图形在三维空间中很像倒置的茶杯(参见例2.11)。通过这个类比也可以看出，此种函数的扁平点确实是最大值点，因为在这一点函数的斜率都是负的。更一般地说，凹函数具有其函数曲面在任何一点的切平面之下这一性质，而最大值点的水平切平面是这种性质的一个特例。

例2.10　二阶条件：健康状况的最终讨论

在例2.6中，我们考虑健康状况的函数是：

$$y = f(x_1, x_2) = -x_1^2 + 2x_1 - x_2^2 + 4x_2 + 5 \tag{2.85}$$

最大值的一阶条件为：

$$\begin{aligned} f_1 &= -2x_1 + 2 = 0 \\ f_2 &= -2x_2 + 4 = 0 \end{aligned} \tag{2.86}$$

即有：

$$\begin{aligned} x_1^* &= 1 \\ x_2^* &= 2 \end{aligned} \tag{2.87}$$

(2.85)式的二阶偏导数是：

$$\begin{aligned} f_{11} &= -2 \\ f_{22} &= -2 \\ f_{12} &= 0 \end{aligned} \tag{2.88}$$

这些偏导数显然符合(2.83)式和(2.84)式，因此满足局部最大值的充要条件。[②]

请回答：描述健康状况凹函数的形状，并说明为什么只有一个全局最大值点。

2.8.6　有约束条件的最大值问题

作为二阶条件的另一种说明，我们考虑函数

$$y = f(x_1, x_2) \tag{2.89}$$

---

① 证明方法是在(2.81)式上加一个 $(f_{12}dx_2)^2/f_{11}$ 再减一个 $(f_{12}dx_2)^2/f_{11}$，做因式分解。但这种方法只适用于该特殊情况。一般的证法是将(2.81)式写成矩阵的形式，再利用 $X^T=[dx_1 \quad dx_2]$ 的二次型证明。(2.83)式和(2.84)式的作用是保证海森矩阵 $\begin{bmatrix} f_{11} & f_{12} \\ f_{21} & f_{22} \end{bmatrix}$ 负定。特别地，(2.84)式保证了海森矩阵值为正。详见本章扩展部分的讨论。

② 注意(2.88)式，它使函数在整个定义域上(不仅临界点，还包括所有可选择点)满足最大值的二阶条件，故函数是凹的。但对于一般的函数来说不一定有这个条件，我们实际上只要求二阶条件在局部最大值临界点上得到满足。

在线性约束条件

$$c - b_1 x_1 - b_2 x_2 = 0 \tag{2.90}$$

下求最大值的问题(其中 c, b_1, b_2 是常数)。这种问题在本书中会经常遇到,是前面讨论过的有约束条件的最大值问题的一种特例。我们已经知道为得出最大值问题的一阶条件,首先需要建立如下的拉格朗日表达式:

$$\mathscr{L} = f(x_1, x_2) + \lambda(c - b_1 x_1 - b_2 x_2) \tag{2.91}$$

此式关于 x_1、x_2 和 λ 的偏导数满足如下结论:

$$\begin{aligned} f_1 - \lambda b_1 &= 0 \\ f_2 - \lambda b_2 &= 0 \\ c - b_1 x_1 - b_2 x_2 &= 0 \end{aligned} \tag{2.92}$$

一般来说,这样的方程组总可以解出使 f 最大的 x_1, x_2 和 λ 的最优值。为了确保以这种方式得到的点是局部最大值点,我们仍需要利用二阶全微分考察一下离开临界点时的运动:

$$\mathrm{d}^2 y = f_{11}\mathrm{d}x_1^2 + 2f_{12}\mathrm{d}x_1\mathrm{d}x_2 + f_{22}\mathrm{d}x_2^2 \tag{2.93}$$

然而,在这种情况下,并不是 x 的所有变化都是可行的。只有继续满足约束条件的 x_1 与 x_2 的值才被认为是临界点的有效选择。为了考察这种变化,我们需要计算约束条件的全微分:

$$-b_1\mathrm{d}x_1 - b_2\mathrm{d}x_2 = 0 \tag{2.94}$$

即

$$\mathrm{d}x_2 = -\frac{b_1}{b_2}\mathrm{d}x_1 \tag{2.95}$$

(2.95)式显示了 x_1 与 x_2 远离临界点时运动的相对变化。进一步研究这个问题,我们需要使用一阶条件。这意味着从前两个方程导出:

$$\frac{f_1}{f_2} = \frac{b_1}{b_2} \tag{2.96}$$

与(2.95)式结合,有:

$$\mathrm{d}x_2 = -\frac{f_1}{f_2}\mathrm{d}x_1 \tag{2.97}$$

将 $\mathrm{d}x_2$ 的值代入(2.93)式,可得到 $\mathrm{d}^2 y$ 为负的条件为:

$$\begin{aligned} \mathrm{d}^2 y &= f_{11}\mathrm{d}x_1^2 + 2f_{12}\mathrm{d}x_1\left(-\frac{f_1}{f_2}\mathrm{d}x_1\right) + f_{22}\left(-\frac{f_1}{f_2}\mathrm{d}x_1\right)^2 \\ &= f_{11}\mathrm{d}x_1^2 - 2f_{12}\frac{f_1}{f_2}\mathrm{d}x_1^2 + f_{22}\frac{f_1^2}{f_2^2}\mathrm{d}x_1^2 \end{aligned} \tag{2.98}$$

合并同类项提出公分母,有:

$$\mathrm{d}^2 y = (f_{11}f_2^2 - 2f_{12}f_1 f_2 + f_{22}f_1^2)\frac{\mathrm{d}x_1^2}{f_2^2} \tag{2.99}$$

因此,为了使 $\mathrm{d}^2 y<0$,一定有:

$$f_{11}f_2^2 - 2f_{12}f_1 f_2 + f_{22}f_1^2 < 0 \tag{2.100}$$

2.8.7　拟凹函数

虽然(2.100)式看起来有些复杂,但它具有很重要的意义。它定义了一类被称为拟凹函数(quasi-concave functions)的函数。拟凹函数具有这样的性质:对任意给定常数 c,当函数值 $f(x_1, x_2)>c$ 时,其定义域[即(x_1, x_2)]必为凸集(即集合中任意两点的连线被完全包含在集合内)。这

种函数在微观经济学中有广泛的应用，在第3章我们会细致地分析拟凹性，并赋予它一个相对简单的经济学意义。练习题2.9和2.10分别列举了两个常用的拟凹函数，例2.11展示了凹函数和拟凹函数之间的关系。

例2.11 凹函数和拟凹函数

可以用下面的函数来说明凹函数和拟凹函数的区别[①]：

$$y = f(x_1, x_2) = (x_1 x_2)^k \tag{2.101}$$

式中，$x_1, x_2, k>0$。

不管k取多少，函数都是拟凹的。我们可以看它的“等高线”，设定$y=c$，就有：

$$y = c = (x_1 x_2)^k \quad 或 \quad x_1 x_2 = c^{1/k} = c' \tag{2.102}$$

这是标准的双曲线，显然$y>c$的点集是凸的，因为上式正好给出了双曲线的边界。

用(2.99)式可以从数学上证明它的拟凹性。尽管这里的代数运算有点烦琐，但花点工夫弄懂它还是值得的。(2.99)式中各个导数值如下：

$$\begin{aligned} f_1 &= k x_1^{k-1} x_2^k \\ f_2 &= k x_1^k x_2^{k-1} \\ f_{11} &= k(k-1) x_1^{k-2} x_2^k \\ f_{22} &= k(k-1) x_1^k x_2^{k-2} \\ f_{12} &= k^2 x_1^{k-1} x_2^{k-1} \end{aligned} \tag{2.103}$$

因此，有：

$$\begin{aligned} f_{11} f_2^2 - 2 f_{12} f_1 f_2 + f_{22} f_1^2 &= k^3(k-1) x_1^{3k-2} x_2^{3k-2} - 2k^4 x_1^{3k-2} x_2^{3k-2} + k^3(k-1) x_1^{3k-2} x_2^{3k-2} \\ &= 2k^3 x_1^{3k-2} x_2^{3k-2}(-1) \end{aligned} \tag{2.104}$$

该值显然是负的，所以它一定是拟凹的。

而该函数的凹凸性取决于k的大小。如果$k<0.5$，则函数就是凹的；反之，如果$k>0.5$，则函数就是凸的。直观地看，当$x_1=x_2$时，有：

$$y = (x_1^2)^k = x_1^{2k} \tag{2.105}$$

下面证明这个结论。利用(2.105)式的偏导数，凹性的判别条件是：

$$\begin{aligned} f_{11} f_{22} - f_{12}^2 &= k^2(k-1)^2 x_1^{2k-2} x_2^{2k-2} - k^4 x_1^{2k-2} x_2^{2k-2} \\ &= x_1^{2k-2} x_2^{2k-2}[k^2(k-1)^2 - k^4] \\ &= x_1^{2k-2} x_2^{2k-2}[k^2(-2k+1)] \end{aligned} \tag{2.106}$$

(2.106)式为正(即函数为凹函数)的条件是：

$$-2k + 1 > 0 \quad 或 \quad k < 0.5$$

否则，当$k>0.5$时，函数为凸函数。

作图表示法 图2.4是当k取三个特定值(0.2、0.5、1)时的三维图形。注意这三个函数的等高线都是双曲线，并且是凸的，即对给定的y，这些函数图形很相似。这表明了该函数的拟凹性。三个图形的主要差别在于其凹凸性，即随着x的变化，y的改变速度的变化趋势。在图2.4(a)中($k=0.2$)，随着x增大，y的增速减缓，形成一个像倒扣着的茶杯一样向上鼓的图形，所以是凹函数。当$k=0.5$，两个自变量一同变化时，y的变化看起来是线性的，可以认为是凹函数和凸函数的

① 这个函数是柯布-道格拉斯函数的一个特例，关于柯布-道格拉斯函数详见练习题2.10和本章扩展部分。

分界线。而当 $k=1$ 时，如图 2.4(c)所示，同时增加两个自变量会让 y 增加得越来越快，从函数的“山脊”的走向能看出这已经是凸函数了。更一般地说，函数在它的切平面上方，而对于凹性函数，函数应当在切平面下方。

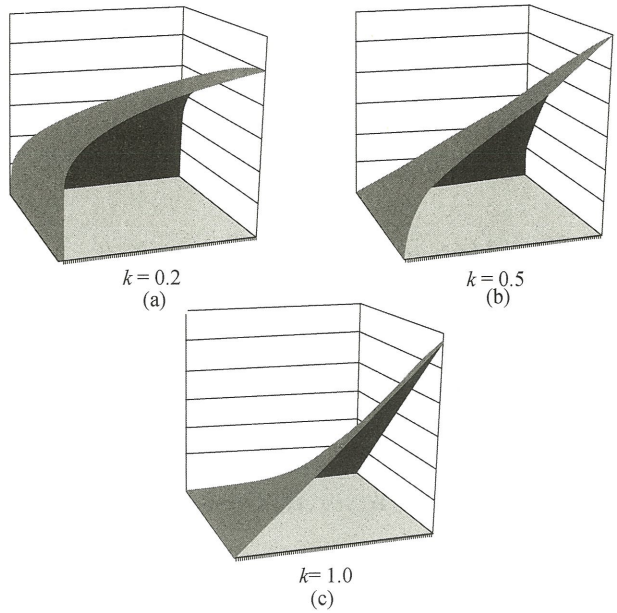


图 2.4　凹函数和拟凹函数

三个函数都是拟凹的，因为对于固定的 y，它们的等高线是凸的。但只有 $k=0.2$ 时函数才是严格凹的。当 $k=1.0$ 时，函数显然不是凹的，因为函数曲面不在其切平面之下。

仔细看图 2.4(a)，读者会发现凹函数必然是拟凹的。练习题 2.9 就是要求读者证明此结论。从这个例子也能看出，它的逆命题是错误的——拟凹函数不一定是凹的。本书中的大部分函数正是这样，具有拟凹性但未必是凹的。

请回答：当 x_1, x_2 满足线性约束条件时，图 2.4(a)和图 2.4(c)都有最大值，但没有约束条件时，就只有图 2.4(a)才有最大值。请解释原因。

2.9　齐次函数

很多从经济理论中引出的函数本身就具有一些数学上的特殊性质。其中一类重要的性质是，当函数所有(或大部分)自变量同时按相同比例变动时函数值的变化规律。这个问题的背景是：所有商品价格同时上涨 10%，会发生什么变化；或者把工厂所有投入的生产要素加倍，产量会如何变化；等等。研究这类问题自然要用到齐次函数的概念。具体来说，一个多元函数 $f(x_1, x_2, \cdots, x_n)$，如果满足

$$f(tx_1, tx_2, \cdots, tx_n) = t^k f(x_1, x_2, \cdots, x_n) \tag{2.107}$$

则称其为 k 次齐次函数。

最重要的齐次函数是 $k=1$ 和 $k=0$ 两类。如果函数是一次齐次的，那么所有的自变量加倍后，函数值也加倍；如果函数是零次齐次的，那么所有的自变量加倍后，函数值不变。还有的方程

只关于其自变量的某个子集齐次，即某几个自变量加倍而其余的不变时，函数值加倍。但通常情况下，我们提到的齐次性指的都是函数中所有自变量的齐次性。

2.9.1 齐次函数的偏导数

一个 k 次齐次可微函数的各个偏导数是 $k-1$ 次齐次的。用齐次性的定义就能证明。例如，对(2.107)式关于 x_1 求偏导数，有：

$$\frac{\partial f(tx_1,\cdots,tx_n)}{\partial x_1}=\frac{\partial f(tx_1,\cdots,tx_n)}{\partial tx_1}\cdot\frac{\partial tx_1}{\partial x_1}=f_1(tx_1,\cdots,tx_n)\cdot t=t^k\frac{\partial f(x_1,\cdots,x_n)}{\partial x_1}$$

或

$$f_1(tx_1,\cdots,tx_n)=t^{k-1}f_1(x_1,\cdots,x_n) \tag{2.108}$$

可见 f_1 是满足 $k-1$ 次齐次定义的。由于边际的概念在微观经济学中的应用非常广泛，这个性质就很有意义，它表明边际效应的某些重要性质可以直接由基础函数的性质推导出来。

2.9.2 欧拉定理

齐次函数的另一个重要性质是对比例因子 t 求导得到的。对(2.107)式的两边求导得：

$$kt^{k-1}f(x_1,\cdots,x_n)=x_1f_1(tx_1,\cdots,tx_n)+\cdots+x_nf_n(tx_1,\cdots,tx_n)$$

令 $t=1$，方程变为：

$$kf(x_1,\cdots,x_n)=x_1f_1(x_1,\cdots,x_n)+\cdots+x_nf_n(x_1,\cdots,x_n) \tag{2.109}$$

这就是齐次函数的欧拉定理(以发现自然数 e 的那个伟大数学家的名字命名)。它说明了对于齐次函数，其函数值与其各个偏导数有确定的关系。经济问题中一些重要的关系正是基于这个定理而发现的。

2.9.3 位似函数

齐次函数经过任意的单调映射得到的函数叫作位似函数(homothetic function)。[①] 从定义可知，位似函数保持了原函数自变量到函数值对应的序关系。对于函数 f，如果一组自变量对应的函数值大于另一组，那么经过单调映射后前者的函数值仍大于后者。但是由于单调映射有很多可能的形式，原齐次函数的很多性质是不能保持的。例如，函数 $f(x_1,x_2)=x_1x_2$ 显然是二次齐次的，自变量都加倍后函数值增为原来的4倍，但是 f 经过简单“加1”的单调变换[如 $F(f)=f+1=x_1x_2+1$]后，就不再是齐次函数。所以，除少数特例外，一般的位似函数不具有原函数的齐次性。但是位似函数保留了齐次函数一个很好的性质，即函数各个自变量之间的隐含替代关系(implicit trade-offs)只取决于自变量之间的比例，而不取决于它们的绝对值。我们用一个含两个变量的隐函数 $y=f(x_1,x_2)$ 说明。回忆隐函数定理，为保证函数值不变，自变量间的隐含替代关系必须满足：

$$\frac{\mathrm{d}x_2}{\mathrm{d}x_1}=-\frac{f_1}{f_2}$$

如果 f 是 k 次齐次函数，则其偏导数是 $k-1$ 次齐次函数。替代关系为：

$$\frac{\mathrm{d}x_2}{\mathrm{d}x_1}=-\frac{t^{k-1}f_1(x_1,x_2)}{t^{k-1}f_2(x_1,x_2)}=-\frac{f_1(tx_1,tx_2)}{f_2(tx_1,tx_2)} \tag{2.110}$$

① 因为单调映射的极限情况是保持函数不变，所以所有齐次函数都是位似函数。

现在令 $t=1/x_2$，则(2.110)式变为：

$$\frac{\mathrm{d}x_2}{\mathrm{d}x_1}=-\frac{f_1(x_1/x_2,1)}{f_2(x_1/x_2,1)} \tag{2.111}$$

可见 f 中的隐含替代关系只由 x_1 与 x_2 的相对比例决定。现在假设 f 经过单调映射变为 $F(F'>0)$，对于新的位似函数 $F[f(x_1,x_2)]$，x_1 和 x_2 的替代关系为：

$$\frac{\mathrm{d}x_2}{\mathrm{d}x_1}=-\frac{F'f_1(x_1/x_2,1)}{F'f_2(x_1/x_2,1)}=-\frac{f_1(x_1/x_2,1)}{f_2(x_1/x_2,1)} \tag{2.112}$$

这样我们就证明了位似函数保持替代关系不变，且替代关系只与相对比例有关。有了这条性质，我们在本书许多地方用二维图讨论一些理论结果是有指导意义的。(2.112)式可以使我们集中于关键变量的比率上，而非绝对值上。

例 2.12　基数性质和序数性质

在经济问题中，有时需要定量地确定变量的大小，例如研究生产函数时，需要确切地算出再多雇用 1 个工人会产生多少额外产出，这被称为生产函数的“基数性质”。而有时，只需要确定不同点函数的大小关系。例如在效用理论中，我们假定人们能够对不同的商品组合按偏好排序，并选择排序最靠前的一个，但是每种商品组合的效用数值并不唯一。由单调映射的定义可知，单调映射保持函数的序数性质不变。但一般来说，单调映射并不能保证函数的基数性质不变。

我们用例 2.11 中的函数来说明它们的差别。对于不同的参数 k，考虑单调映射作用于函数

$$f(x_1,x_2)=(x_1x_2)^k \tag{2.113}$$

我们证明了拟凹性(是一种序数性质)对一切 k 成立，而当求解在某线性约束条件下最大(或最小)值问题时，用何种单调映射结果都一样。然而，只有当 k 满足一定条件时，(2.113)式才表示为凹函数(是一种基数性质)，对于一般的单调映射，f 的凹性不一定能保持。

下面我们再以(2.113)式为例说明齐次函数和位似函数的区别。两个自变量以同比例增加，有：

$$f(tx_1,tx_2)=t^{2k}x_1x_2=t^{2k}f(x_1,x_2) \tag{2.114}$$

即齐次函数的次数由 k 决定，也就是说，一般的单调映射不能保证齐次次数不变。但(2.113)式是位似函数，因为

$$\frac{\mathrm{d}x_2}{\mathrm{d}x_1}=-\frac{f_1}{f_2}=-\frac{kx_1^{k-1}x_2^k}{kx_1^kx_2^{k-1}}=-\frac{x_2}{x_1} \tag{2.115}$$

即 x_1 和 x_2 之间的替代关系只由这两个变量的比例决定，与 k 无关，所以位似性是序数性质。我们后面会看到，这个性质为作图分析提供了非常大的帮助。

请回答：考虑这样的单调映射 $f(x_1,x_2,k)=x_1x_2+k$(k 为任意常数)，对于不同的 k，这个例子中的讨论将如何改变？

2.10　积　分

积分是微积分的另一个工具，在微观经济学中有许多应用。积分主要用于计算各类经济产

出，同时也被用于汇总多期或者多人的经济产出。下面将会对积分进行简要的介绍，如果读者希望了解更完整的背景知识，可以阅读本章最后的参考文献。

2.10.1 不定积分

规范地说，积分是微分的逆运算。在计算函数$f(x)$的积分时，只需要找到一个函数，使得这个函数的导数是$f(x)$即可。我们称函数$F(x)$为不定积分，$F(x)$有这样一个性质：

$$\frac{\mathrm{d}F(x)}{\mathrm{d}x} = F'(x) = f(x) \tag{2.116}$$

如果这个函数$F(x)$存在，则记为：

$$F(x) = \int f(x)\,\mathrm{d}x \tag{2.117}$$

我们将在之后详细说明为何要使用这个符号。首先，来看几个例子。如果$f(x)=x$，那么

$$F(x) = \int f(x)\,\mathrm{d}x = \int x\mathrm{d}x = \frac{x^2}{2} + C \tag{2.118}$$

式中，C是任意的“积分常数”，常数的导数为0。这个结果的正确性很容易被验证：

$$F'(x) = \frac{\mathrm{d}(x^2/2 + C)}{\mathrm{d}x} = x + 0 = x \tag{2.119}$$

2.10.2 不定积分的计算

对于不同的函数$f(x)$，计算不定积分的难度也不同，某些函数的不定积分计算十分困难和令人头疼，某些函数的不定积分甚至不存在。这里，我们会介绍三种不定积分的计算方法，不过，需要注意的是，这些方法并不能解决所有的问题。

1. 试猜法

求解积分(不定积分)最普遍的方法就是逆推哪个函数的导数是$f(x)$，以下是几个简单的例子：

$$\begin{aligned}
F(x) &= \int x^2\mathrm{d}x = \frac{x^3}{3} + C \\
F(x) &= \int x^n\mathrm{d}x = \frac{x^{n+1}}{n+1} + C \\
F(x) &= \int (ax^2 + bx + c)\,\mathrm{d}x = \frac{ax^3}{3} + \frac{bx^2}{2} + cx + C \\
F(x) &= \int \mathrm{e}^x\mathrm{d}x = \mathrm{e}^x + C \\
F(x) &= \int a^x\mathrm{d}x = \frac{a^x}{\ln a} + C \\
F(x) &= \int\left(\frac{1}{x}\right)\mathrm{d}x = \ln(|x|) + C \\
F(x) &= \int(\ln x)\,\mathrm{d}x = x\ln x - x + C
\end{aligned} \tag{2.120}$$

通过对上述函数微分可知，上述函数都服从$F'(x)=f(x)$这一性质。注意，上述例子中都存在一个积分常数，这是由于常数的微分等于0。(2.120)式中的方程(或其中几个式子的组合)对于本书的学习已经足够了。不过，在试猜法失效时，还可以使用另外两种方法。

2. 换元法

对函数进行适当的换元有时能够很大程度简化积分的难度。例如，$2x/(1+x^2)$ 的积分结果并不是显而易见的。不过，如果我们假设 $y=1+x^2$，那么 $dy=2xdx$，同时

$$\int \frac{2x}{1+x^2}dx = \int \frac{1}{y}dy = \ln(|y|) = \ln(|1+x^2|) \tag{2.121}$$

这一方法的关键在于将原方程分解成 y 和 dy 两项。读者如果想熟练掌握换元法，就得做大量的练习。

3. 分部积分法

这一积分方法是利用了微分的一个性质：对任意两个函数 u 和 v，$duv=udv+vdu$。对上式积分可得：

$$\int duv = uv = \int udv + \int vdu \quad 或 \quad \int udv = uv - \int vdu \tag{2.122}$$

这种积分方法的策略就是定义函数 u 和 v，将对方程左侧未知积分的求解转化为对方程右侧两个已知表达式的计算。例如，求解 xe^x 的积分时，直接对其积分也不能很容易地得出结果。不过，我们可以定义 $u=x$（就有 $du=dx$），同时 $dv=e^xdx$（即 $v=e^x$）。那么，原积分可转化为：

$$\int xe^x dx = \int udv = uv - \int vdu = xe^x - \int e^x dx = (x-1)e^x + C \tag{2.123}$$

同样地，读者只有通过练习才能熟练掌握如何恰当定义 u 和 v。

2.10.3　定积分

刚才我们学习了不定积分的相关知识——它们只提供一个函数积分的一般函数形式。与此不同的是，定积分则是指特定定义域内函数下方图形的面积，如图 2.5 所示。我们希望求解函数 $f(x)$ 下方从 $x=a$ 到 $x=b$ 之间区域的面积，一种方法就是将此区间划分为细条 $x(\Delta x)$，而后再将图中所示的矩形面积相加，即：

$$f(x)\text{ 下方的面积} \approx \sum_i f(x_i)\Delta x_i \tag{2.124}$$

(2.124)式旨在表明，对于区间内的 x 值，每个矩形的高度可用 $f(x)$ 值近似。通过对上式中的 Δx 求极限，可以得到待求面积的精确值，表示为：

$$f(x)\text{ 下方的面积} = \int_{x=a}^{x=b} f(x)dx \tag{2.125}$$

这就解释了形状奇怪的积分符号的由来——积分符号其实是一个变形的 S，也就是“求和”(sum)的意思。正如我们将看到的，积分是在某段区域内对连续函数值求和的一种常用方法。

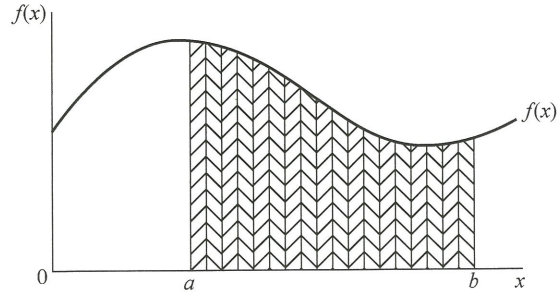


图 2.5　定积分的定义是函数图形下方区域的面积

定积分被定义为用于衡量曲线下方矩形面积的加总，如图中所示。每个矩形的面积是 $f(x)dx$。

2.10.4 微积分基本定理

如果已知函数$f(x)$的不定积分$F(x)$,那么求(2.125)式中的定积分的值就很简单。此时我们有:

$$f(x)\text{ 下方的面积}=\int_{x=a}^{x=b}f(x)\,\mathrm{d}x=F(b)-F(a) \tag{2.126}$$

即在计算定积分时,我们需要做的是求解$f(x)$的不定积分,再用积分函数的上限值减去其下限值。这一结果将微积分的两个主要工具——微分和积分直接联系在一起,因此有时也被称为微积分基本定理(fundamental theorem of calculus)。在例2.13中,我们将看到上述结果不仅能够计算面积,还有一些更普遍的作用。微积分基本定理可以用来阐释经济学中一个很基础的概念——"存量"和"流量"的区别。

例2.13 存量和流量

使用定积分能够有效地对任意连续的跨期流量函数求和。例如,假设一个国家的净人口增长数量(出生人数减死亡人数)可以近似表示为函数$f(t)=1\,000\mathrm{e}^{0.02t}$,即净人口数量以每年2%的比率增加——第0年新增1 000人,第1年新增1 020人,第2年新增1 041人,以此类推。假设我们想知道50年内总的新增人口数量,如果不使用积分,计算会相当烦琐,而使用微积分基本定理,计算将得到简化:

$$\begin{aligned}\text{人口增量}&=\int_{t=0}^{t=50}f(t)\,\mathrm{d}t=\int_{t=0}^{t=50}1\,000\mathrm{e}^{0.02t}\,\mathrm{d}t=F(t)\Big|_0^{50}\\&=\frac{1\,000\mathrm{e}^{0.02t}}{0.02}\Big|_0^{50}=\frac{1\,000\mathrm{e}}{0.02}-50\,000=85\,914\end{aligned} \tag{2.127}$$

式中,$|_a^b$表示$F(b)-F(a)$。通过以上计算得出结论,在未来50年内总人口将增长约86 000人。注意微积分基本定理中包含了"流量"的概念即净人口增长数量(以年作为计数单位),以及"存量"的概念即总人口数量(测度一个特定时间点的数量,没有时间维度上的变化)。同时还要注意计算结果86 000仅指50年内的总人口增量。如果想了解某一时间点的实际总人口,则需要将人口增量加上第0年的初始人口数量。而初始人口数量在一个特定问题中会是一个常数。

现在考虑一个更有经济学内涵的应用。假设一个工厂的总成本为$C(q)=0.1q^2+500$(其中q为一段时间内的产量)。$0.1q^2$代表可变成本(随产量变化而变化的成本),常数500代表固定成本。生产这种产品的边际成本可以通过对成本函数求微分得到[$\mathrm{MC}=\mathrm{d}C(q)/\mathrm{d}q=0.2q$],所以边际成本随$q$的增加而增加,固定成本则在微分中被消去。当$q=100$时,与生产相关的总成本是多少呢?一种方法是直接使用总成本函数:$C(100)=0.1\times(100)^2+500=1\,500$。另一种方法则是对边际成本函数进行积分运算,积分区间是从0到100,得到:

$$\text{可变成本}=\int_{q=0}^{q=100}0.2q\,\mathrm{d}q=0.1q^2\Big|_0^{100}=1\,000-0=1\,000 \tag{2.128}$$

注意还需要加上500的固定成本(即这个问题中的积分常数)才能得到最终的总成本。当然,使用积分求解总成本比直接使用成本函数求解要麻烦得多。不过,这种方法表明,可以使用积分计算边际成本函数曲线下方的面积来求解两个产出水平之间的总可变成本——这个结论在某些图形应用中会有帮助。

请回答:如何计算产出水平由100扩大到110时的总可变成本?请解释为何计算中没有包括固定成本。

2.10.5　定积分的微分运算

通常，在计算积分的最大值时，我们希望对定积分进行微分运算。尽管有时进行这样的微分操作会相当复杂，但是有一些规律能够帮助简化运算。

1. 对积分变量求微分

这是一个很刁钻但十分重要的问题。定积分是一个常数，故它的导数为 0，即：

$$\frac{\mathrm{d}\int_a^b f(x)\,\mathrm{d}x}{\mathrm{d}x}=0 \tag{2.129}$$

求和运算在写下定积分符号的时候就已经完成了。无论积分变量是 x 还是 t，或者其他变量，这个定积分值都不会变化（不过还需参见规律 3）。

2. 对积分上限求微分

改变积分上限无疑会改变定积分的值。此时，我们需要区分积分上限变量（x）和积分变量（t）。其微分结果是微积分基本定理的一个简单应用。例如：

$$\frac{\mathrm{d}\int_a^x f(t)\,\mathrm{d}t}{\mathrm{d}x}=\frac{\mathrm{d}[F(x)-F(a)]}{\mathrm{d}x}=f(x)-0=f(x) \tag{2.130}$$

式中，$F(x)$ 是 $f(x)$ 的不定积分。读者可以参见图 2.5 来理解为何上述结论是合理的——我们研究的是定积分的值是如何随着积分上限 x 的微小变化而发生变化的。显然，定积分的变化量就是 $f(x)$ 的高度（注意这个值最终取决于 x 的取值）。

如果积分上限是 x 的函数，那么可以使用链式法则求解：

$$\frac{\mathrm{d}\int_a^{g(x)} f(t)\,\mathrm{d}t}{\mathrm{d}x}=\frac{\mathrm{d}[F(g(x))-F(a)]}{\mathrm{d}x}=\frac{\mathrm{d}[F(g(x))]}{\mathrm{d}x}=f\frac{\mathrm{d}g(x)}{\mathrm{d}x}=f(g(x))g'(x) \tag{2.131}$$

同样地，最后的微分值取决于 x 的取值。

最后需要注意，如果是对积分下限求微分，只要改变表达式前的正负号就可以了：

$$\frac{\mathrm{d}\int_{g(x)}^b f(t)\,\mathrm{d}t}{\mathrm{d}x}=\frac{\mathrm{d}[F(b)-F(g(x))]}{\mathrm{d}x}=-\frac{\mathrm{d}F(g(x))}{\mathrm{d}x}=-f(g(x))g'(x) \tag{2.132}$$

3. 对其他相关变量求微分

在某些情况下我们要对多元函数求积分。一般来说，这会涉及多重积分，求导会显得比较复杂。不过，这里存在一种简单的情况。假设存在一个二元函数 $f(x,y)$，对其中的变量 x 进行积分运算，这一积分值显然会与变量 y 的取值有关，故我们希望了解 y 值变化时积分值随之变化的情况。在这种情况下，可以通过“将微分移入积分符号内”得到结果，即：

$$\frac{\mathrm{d}\int_a^b f(x,y)\,\mathrm{d}x}{\mathrm{d}y}=\int_a^b f_y(x,y)\,\mathrm{d}x \tag{2.133}$$

这个表达式告诉我们，可以首先求解 $f(x,y)$ 对 y 的偏微分，而后再进行积分运算。当然，最后的运算结果取值依然可能与 y 的取值有关，但这种表达方式相较于原始表达式能够产生更多的经济学意义。读者可以通过完成练习题 2.8 找到更多运用定积分的例子。

2.11 动态最优化

微观经济学中的一些最优化问题可能会涉及多个时期。[①] 我们希望找到一个变量或者一个变量集合的最优时间路径，使得某些目标达到最优化。例如，个人希望能够在生命周期中选择合适的消费方式来实现效用最大化；公司希望找到合适的投入产出模式使得未来利润的现值最大化。这一类问题的难点在于当期的决策会影响到下一期的结果。因此，在选择最优路径时需要明确考虑到这些相互关系。如果当期的决策对之后的时期没有影响，那么也就不存在“动态”结构——个体只需要独立地在每一期作出最优化决策，而不需要考虑对之后的影响。不过在这里，我们希望明确地考虑动态问题对决策的影响。

2.11.1 最优控制问题

数学家和经济学家提出了很多解决动态最优化问题的方法。本章最后的参考文献部分提供了对这些方法的详细介绍。这里我们把注意力集中在一种问题上——最优控制问题，这种问题的解决方法与之前讨论过的最优问题有很多相似之处。这一类问题的分析框架相对简单。假设一个决策者希望在时间区间$[t_0,t_1]$内找到变量$x(t)$的最优时间路径。x随t的变化由下述微分方程表示：

$$\frac{\mathrm{d}x(t)}{\mathrm{d}t}=g[x(t),c(t),t] \tag{2.134}$$

式中，变量$c(t)$被用于“控制”$x(t)$的变化。在每一个时期，决策者都能够得到$f[x(t),c(t),t]$的收益，同时其目标是最大化$\int_{t_0}^{t_1} f[x(t),c(t),t]\mathrm{d}t$。通常，这个问题会受到变量$x$的“端点”的约束，被写成：$x(t_0)=x_0$，$x(t_1)=x_1$。

注意这个问题是“动态的”。任何关于当期x变化的决策不仅会影响未来x的取值，还会影响未来的产出函数f的取值。现在的问题是如何保证$x(t)$处于最优路径上。

经济直觉能够帮助我们解决这个问题。假设我们仅关注在每个特定的时间点选择合适的x和c使得函数f能够取得最大值。这种“缺乏远见”的方法有两个难点。第一，我们并不能够真正自由地在任意时间点选择x的取值。相反，x的取值会取决于其初始值x_0和其变化历史[由(2.134)式确定]。第二，这种缺乏远见的方法忽略了动态问题的本质，即没有考虑当期决策对未来的影响。我们需要使用一些方法来反映当期决策的动态影响，即需要考虑未来的影响，以修正x的取值(价格)。这种隐含价格与本章之前学到的拉格朗日乘数有诸多相似之处，故而我们将这个隐含价格记为$\lambda(t)$。显然，x的重要性会随着时间变化，故λ也是时间的函数。

2.11.2 最大值原理

现在我们来看在单一时间点上决策者的决策问题。决策者不仅关注目标函数$f[x(t),c(t),t]$的现值，还关注$x(t)$值的隐性变化。$x(t)$的现值由$\lambda(t)x(t)$给出，这个值的即时变化率由下式给出：

---

① 这一部分我们都将动态最优化问题当成跨期问题处理。在其他情形中，我们也可以运用相同的方法求解最优化问题。在多个公司和个人的问题中，若当事者的选择会影响到其他主体，就可以运用这种方法。该部分内容只会应用于本书少数几个地方，在这里仅供读者参考。

$$\frac{\mathrm{d}[\lambda(t)x(t)]}{\mathrm{d}t}=\lambda(t)\frac{\mathrm{d}x(t)}{\mathrm{d}t}+x(t)\frac{\mathrm{d}\lambda(t)}{\mathrm{d}t} \tag{2.135}$$

同时，在任意时间 t，决策者关注的整体价值函数为[①]：

$$H=f[x(t),c(t),t]+\lambda(t)g[x(t),c(t),t]+x(t)\frac{\mathrm{d}\lambda(t)}{\mathrm{d}t} \tag{2.136}$$

这个综合值代表了当前收益和 x 值的即时变化。现在我们来求解 $x(t)$ 和 $c(t)$ 使得上述表达式达到最优化需要满足的条件[②]：

$$\begin{aligned}&\frac{\partial H}{\partial c}=f_c+\lambda g_c=0 \quad 或 \quad f_c=-\lambda g_c\\&\frac{\partial H}{\partial x}=f_x+\lambda g_x+\frac{\mathrm{d}\lambda(t)}{\mathrm{d}t}=0 \quad 或 \quad f_x+\lambda g_x=-\frac{\mathrm{d}\lambda(t)}{\mathrm{d}t}\end{aligned} \tag{2.137}$$

这就是动态问题的两个最优化条件。这两个条件也经常被称为最大值原理。这种最优控制问题的求解方法最早是由俄罗斯数学家列夫·庞特里亚金(Lev Pontryagin)和他的同事在 20 世纪 60 年代早期提出的。

尽管读者可以通过阅读之后的经济学应用进一步理解最大值原理的逻辑，但我们还是要做一个简要的总结，以便读者深入理解。第一个条件告诉我们，在边际处，方程 f 中增加 c 这一项所带来的收益必须能够平衡该项所引起的 x 变化所带来的损失(其中，这种变化由随时间变化的拉格朗日乘数衡量)，即现在的收益要与未来的成本相等。

第二个条件则与 $x(t)$ 的最优时间路径所具有的特征相关。这意味着，在边际处，通过增加当期 x 所获得的净收益(既包括通过函数 f 获得的增量，也包括通过自身变化获得的增量)必须要和 x 的隐性价值的变化平衡，即通过当期增加 x 获得的净现值的增加要与 x 的未来价值的减少相等。

例 2.14　固定供给的分配

这个简单的例子能够清楚地阐述最大值原理。假设一个人从一个富有的叔叔那里继承了 1 000 瓶葡萄酒，他想在未来的 20 年内喝完这些酒，那么他应该如何安排才能够使效用最大化呢？

假设这个人对葡萄酒的效用函数为 $u[c(t)]=\ln c(t)$。那么喝酒获得的效用是边际递减的($u'>0,u''<0$)。个人的目标是最大化下式：

$$\int_0^{20}u[c(t)]\mathrm{d}t=\int_0^{20}\ln c(t)\,\mathrm{d}t \tag{2.138}$$

设在时间点 t 剩余的酒的瓶数是 $x(t)$。这个序列的约束条件是 $x(0)=1\,000,x(20)=0$。同时函数 $x(t)$ 满足微分方程[③]：

---

① 我们将现值的表达式记为 H，表示其与规范动态最优理论使用的哈密尔顿表达式相似。不过，通常哈密尔顿表达式没有(2.136)式中的最后一项。

② 注意 x 在此处并非一个真正的选择变量——它的值由历史决定。对 x 求偏导数等于询问这样一个问题——“如果 $x(t)$ 是最优的，那么它具有什么特点？”

③ 微分方程的这个简单形式(这里 $\mathrm{d}x/\mathrm{d}t$ 仅取决于控制变量 c)意味着这个问题与用“变分法”求解动态最优问题一样。在这个例子中，将 $\mathrm{d}x/\mathrm{d}t$ 代入函数 f，再运用最大化的一阶条件，可以得到一个合并后的简单方程 $f_x=\mathrm{d}f_{\mathrm{d}x/\mathrm{d}t}/\mathrm{d}t$，即所谓的欧拉方程。在第 17 章中，我们会遇到许多欧拉方程。

$$\frac{dx(t)}{dt} = -c(t) \tag{2.139}$$

也就是说，即时的消费数量等于酒存量的减少量。现值的哈密尔顿表达式为：

$$H = \ln c(t) + \lambda[-c(t)] + x(t)\frac{d\lambda}{dt} \tag{2.140}$$

最大值的一阶条件为：

$$\frac{\partial H}{\partial c} = \frac{1}{c} - \lambda = 0$$

$$\frac{\partial H}{\partial x} = \frac{d\lambda}{dt} = 0 \tag{2.141}$$

其中第二个条件要求 λ(葡萄酒的隐性价值)为常数。这就给了我们一个直觉上的提示：由于多消费一瓶酒总会减少一瓶酒的存量，因此任何使不同时期葡萄酒价值不同的解都会产生个人激励以改变行为，在酒便宜时多喝酒而在酒贵时少喝酒。将最大值的第二个条件和第一个条件结合起来，可以得出 $c(t)$ 本身也应为常数。假设 $c(t)=k$，则任意时期剩余的酒的瓶数为 $x(t)=1\,000-kt$。如果 $k=50$，则这个系统能够满足端点约束 $x(0)=1\,000$，$x(20)=0$。当然，在这个例子中，你也许会猜想，最优的计划应当是在20年中每年消费50瓶酒，因为边际效用递减意味着个人在任何时期都不想过度饮酒。最大值原理证实了这个猜想。

更复杂的效用函数 现在我们引入一个更复杂的效用函数，这会带来更有趣的结果。假设在任意时间 t，消费酒所得到的效用为：

$$u[c(t)] = \begin{cases} [c(t)]^{\gamma}/\gamma & \text{如果 } \gamma \neq 0, \gamma < 1 \\ \ln c(t) & \text{如果 } \gamma = 0 \end{cases} \tag{2.142}$$

同时假设消费者未来消费的折扣率为 δ。个人的目标是最大化下式：

$$\int_0^{20} u[c(t)]dt = \int_0^{20} e^{-\delta t}\frac{[c(t)]^{\gamma}}{\gamma}dt \tag{2.143}$$

并且要服从下列约束条件：

$$\frac{dx(t)}{dt} = -c(t)$$

$$x(0) = 1\,000 \tag{2.144}$$

$$x(20) = 0$$

建立现值的哈密尔顿表达式：

$$H = e^{-\delta t}\frac{[c(t)]^{\gamma}}{\gamma} + \lambda(-c) + x(t)\frac{d\lambda(t)}{dt} \tag{2.145}$$

同时，最大值原理要求：

$$\frac{\partial H}{\partial c} = e^{-\delta t}[c(t)]^{\gamma-1} - \lambda = 0$$

$$\frac{\partial H}{\partial x} = 0 + 0 + \frac{d\lambda}{dt} = 0 \tag{2.146}$$

由此，我们可以得出结论，酒存量(λ)的隐性价值为常数(记为常数 k)，并且

$$e^{-\delta t}[c(t)]^{\gamma-1} = k \quad \text{或} \quad c(t) = k^{1/(\gamma-1)}\, e^{\delta t/(\gamma-1)} \tag{2.147}$$

所以，最优的葡萄酒消费量会随时间递减(因为 e 的指数中的系数 t 是负的)，以弥补消费者心中未来消费带来的效用会打折扣的事实。例如，假设 $\delta=0.1$，同时 $\gamma=1$(这个假设是有道理的，具体

原因会在之后的章节中阐述），那么：

$$c(t) = k^{-0.5}\,\mathrm{e}^{-0.05t} \tag{2.148}$$

现在，我们需要找到满足端点条件的 k 值。我们希望：

$$\begin{aligned}\int_0^{20} c(t)\,\mathrm{d}t &= \int_0^{20} k^{-0.5}\,\mathrm{e}^{-0.05t}\mathrm{d}t = -\,20k^{-0.5}\,\mathrm{e}^{-0.05t}\Big|_0^{20} \\ &= -\,20k^{-0.5}(\mathrm{e}^{-1} - 1) = 12.64k^{-0.5} = 1\,000\end{aligned} \tag{2.149}$$

最后，我们得到最优消费计划：

$$c(t) \approx 79\,\mathrm{e}^{-0.05t} \tag{2.150}$$

这个消费计划要求在开始时消费大量的葡萄酒，同时消费量以每年 5% 的比率递减。由于消费量是连续递减的，就需要使用积分计算在特定年份（x）葡萄酒的消费量：

$$\begin{aligned}\text{年份 } x \text{ 的消费量} &\approx \int_{x-1}^{x} c(t)\,\mathrm{d}t = \int_{x-1}^{x} 79\,\mathrm{e}^{-0.05t}\mathrm{d}t = -\,1\,580\,\mathrm{e}^{-0.05t}\Big|_{x-1}^{x} \\ &= 1\,580[\mathrm{e}^{-0.05(x-1)} - \mathrm{e}^{-0.05x}]\end{aligned} \tag{2.151}$$

如果 $x=1$，则第 1 年的葡萄酒消费量约为 77 瓶。消费量平稳减少，到了第 20 年，消费量约为 30 瓶。

请回答：第一个例子其实是第二个例子的一种特殊情况，即 $\delta=\gamma=0$。请分别解释这两个变量如何影响葡萄酒的最优消费路径，并凭直觉解释你的结论（关于跨期最优消费的更多内容，参见第 17 章）。

2.12　数理统计

近年来，微观经济学理论越来越关注与不确定性和不完全信息相关的课题。而想要读懂这方面的大量文献，就需要学习数理统计的知识。因此，这一部分的目的就是总结一些统计学原理，读者在本书不同地方会用到。

2.12.1　随机变量和概率密度函数

随机变量（用数值形式表示）描述的是在一次试验中可能出现的结果。例如，我们抛一枚硬币，并观察硬币落地时是正面向上还是反面向上。如果引入一个随机变量 x，我们就能为这个变量可能出现的结果赋值：

$$x = \begin{cases} 1 & \text{如果正面向上} \\ 0 & \text{如果反面向上} \end{cases}$$

注意，在抛硬币之前，x 的取值可以是 1，也可以是 0。只有在不确定性被消除后（如抛完硬币后），我们才能够确切地知道 x 的取值是多少。①

2.12.2　离散随机变量和连续随机变量

一次随机试验的结果既可能有有限种可能，也可能是一个连续的可能性集合。例如，掷单个

① 有时为区别随机变量和（非随机）代数变量，我们也用 $\tilde{x}$ 表示随机变量。这种记法在具体问题中区别随机变量和非随机变量很有用，我们会在一些情况下用到它。但在没有歧义的时候，我们也不会使用这种特殊的记法。

骰子出现数字的随机变量只有6种结果。如果有两个骰子，我们可以记录骰子向上一面数字的总和(那么就有12种结果，其中一些结果比其他结果发生的可能性更高)，我们也可以分别记录两个骰子的数字(那么就有36种结果，这些结果出现的可能性相同)。上面都是离散随机变量的例子。

相反，连续随机变量可以取一个给定实数区间内的任意值。例如，我们可以把明天室外的温度视为一个连续随机变量(假设能够精确地测量室外温度)，随机变量的范围从-50℃到+50℃。当然，有些温度几乎不可能出现，但在理论上，这一区间内的任意温度都能够被精确测量到。同样地，我们可以把明天特定股票指数变动的百分比视为连续随机变量——范围在-100%到+1 000%之间。当然，在0%附近变化出现的可能性比那些极端值要高得多。

2.12.3 概率密度函数

对任意的随机变量，其概率密度函数(probability density function，PDF)能够体现每一个特定结果出现的概率。对于离散随机变量来说，定义这样的函数没有太大难度。对于抛硬币这个例子，概率密度函数[记为$f(x)$]可以写成：

$$\begin{aligned} f(x=1) &= 0.5 \\ f(x=0) &= 0.5 \end{aligned} \tag{2.152}$$

对于掷一个骰子的例子，它的概率密度函数可以写成：

$$\begin{aligned} f(x=1) &= 1/6 \\ f(x=2) &= 1/6 \\ f(x=3) &= 1/6 \\ f(x=4) &= 1/6 \\ f(x=5) &= 1/6 \\ f(x=6) &= 1/6 \end{aligned} \tag{2.153}$$

注意，在这两个例子中，概率密度函数所指定的概率值的和为1.0。这是由于在定义中已经指明，在一次随机试验中必然只会有一个结果发生。更一般地，如果我们把离散随机变量的每一个结果赋值为$x_i(i=1,\cdots,n)$，就有：

$$\sum_{i=1}^{n} f(x_i) = 1 \tag{2.154}$$

对于连续随机变量，我们必须小心地定义概率密度函数的概念。由于随机变量取的是连续值，如果一个特定的结果(如温度为+25.53470℃)发生的概率值为非零常数，那么概率的总和就会无穷大。所以，对于连续变量的概率密度函数$f(x)$，其性质是$f(x)\mathrm{d}x$被定义为结果x出现的概率，其中$f(x)$为x点的函数值，$\mathrm{d}x$为一个趋近无穷小的区间。使用这个约定，随机试验的概率总和为1.0的这一性质表述如下：

$$\int_{-\infty}^{+\infty} f(x)\,\mathrm{d}x = 1.0 \tag{2.155}$$

2.12.4 一些重要的概率密度函数

任意概率密度函数都要满足$f(x) \geqslant 0$，同时函数值求和(或者积分)为1.0。当然，问题的关键是找到一个能够反映现实生活中随机试验的函数。这里我们介绍四个有用的函数，这些函数的图形如图2.6所示。

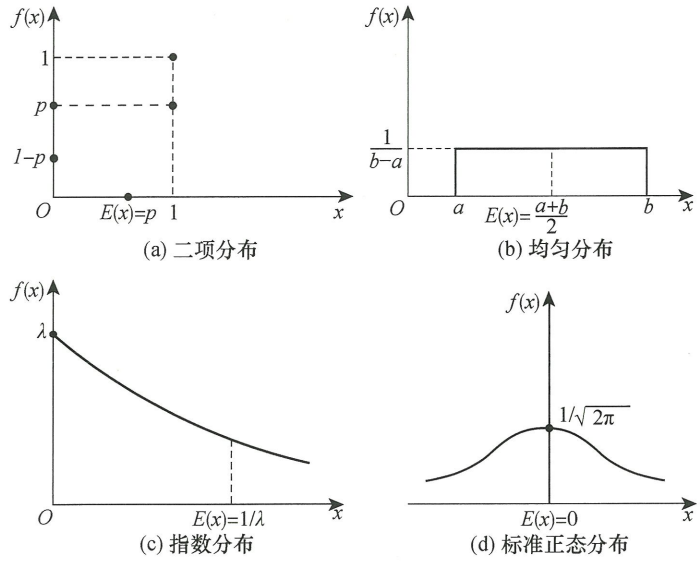


图 2.6　四个常见的概率密度函数

这四个概率密度函数的随机变量被广泛应用。每张图都表明了所示概率密度函数的期望值。

1. 二项分布

这是一个最基础的离散分布。通常 x 只能取 1 和 0 两个值。二项分布的概率密度函数是：

$$\begin{aligned} f(x=1) &= p \\ f(x=0) &= 1-p \end{aligned} \tag{2.156}$$

其中，$0<p<1$。

抛硬币的例子显然是二项分布的一种特殊情况，其中 $p=0.5$。

2. 均匀分布

均匀分布是最简单的连续分布。均匀分布假设在定义域内任意 x 值出现的概率都相等，即：

$$\begin{aligned} f(x) &= \frac{1}{b-a} \quad \text{如果} \quad a \leqslant x \leqslant b \\ f(x) &= 0 \quad\quad\ \ \text{如果} \quad x < a \quad \text{或} \quad x > b \end{aligned} \tag{2.157}$$

注意，这里概率密度函数的积分同样等于 1.0：

$$\int_{-\infty}^{+\infty} f(x)\,\mathrm{d}x = \int_a^b \frac{1}{b-a}\mathrm{d}x = \frac{x}{b-a}\Big|_a^b = \frac{b}{b-a} - \frac{a}{b-a} = \frac{b-a}{b-a} = 1.0 \tag{2.158}$$

3. 指数分布

指数分布也是一种连续分布，其概率随着 x 的增加而指数式地平稳减小，表示为：

$$f(x) = \begin{cases} \lambda \mathrm{e}^{-\lambda x} & \text{如果} \quad x > 0 \\ 0 & \text{如果} \quad x \leqslant 0 \end{cases} \tag{2.159}$$

式中，λ 是一个正的常数。同样地，很容易就能看出函数的积分等于 1.0：

$$\int_{-\infty}^{+\infty} f(x)\,\mathrm{d}x = \int_0^{\infty} \lambda \mathrm{e}^{-\lambda x}\mathrm{d}x = -\mathrm{e}^{-\lambda x}\Big|_0^{\infty} = 0-(-1) = 1.0 \tag{2.160}$$

4. 标准正态分布

标准正态分布（也称高斯分布）是数理统计中最重要的分布类型。它的重要性主要基于中

心极限定理(central limit theorem)，中心极限定理阐述的是随着独立随机变量数量的增加，任何独立随机变量和的分布将逐渐趋近正态分布。由于样本均值可以被视为独立随机变量的和，根据中心极限定理，任意样本均值都服从正态分布，与抽样总体的分布无关。因此，只要一个随机变量可以被视为某种均值，那么就能合理地假设它服从正态分布。

正态分布概率密度函数的数学表达式为：

$$f(x)=\frac{1}{\sqrt{2\pi}}e^{-x^2/2} \tag{2.161}$$

并且，x 的定义域是全体实数。尽管这个函数看上去有些复杂，但它的一些性质十分简洁。首先，这个函数关于 y 轴对称(由于存在 x^2 项)，是一个偶函数；其次，当 x 取值很大或很小时，函数值趋于0；再次，正态分布的概率密度函数在 $x=0$ 处取得最大值，最大值为 $1/\sqrt{2\pi}\approx 0.4$；最后，这个函数的图形形状类似“钟形”——这个形状会贯穿整个统计学的学习。对标准正态分布的密度函数积分比较棘手(虽然在极坐标系下会很简单)。函数中包含常数 $1/\sqrt{2\pi}$ 是为了保证函数的积分等于1.0。

2.12.5 期望

一个随机变量的期望是指这个随机变量预期能够取到的平均值。[①] 期望也是概率密度函数的“重心”。对于一个可以取值 $x_1,x_2,\cdots,x_n$ 的离散随机变量，它的期望值是：

$$E(x)=\sum_{i=1}^{n}x_i f(x_i) \tag{2.162}$$

即每一种结果乘上该结果出现的概率，并将所得到的数值相加。而对于连续随机变量，(2.162)式可以被推广为：

$$E(x)=\int_{-\infty}^{+\infty}xf(x)\,dx \tag{2.163}$$

同样，在这个积分中，每一个 x 值与该值对应的概率相乘。

而根据期望的定义可以推导出一个随机变量的任意函数[记为 $g(x)$]的期望值。例如，对于连续随机变量：

$$E[g(x)]=\int_{-\infty}^{+\infty}g(x)f(x)\,dx \tag{2.164}$$

举一个特殊的例子，考虑线性函数 $y=ax+b$。那么有：

$$\begin{aligned}E(y)=E(ax+b)&=\int_{-\infty}^{+\infty}(ax+b)f(x)\,dx\\&=a\int_{-\infty}^{+\infty}xf(x)\,dx+b\int_{-\infty}^{+\infty}f(x)\,dx=aE(x)+b\end{aligned} \tag{2.165}$$

有时可以使用累积分布函数(cumulative distribution function，CDF)来表述期望。累积分布函数的定义为：

$$F(x)=\int_{-\infty}^{x}f(t)\,dt \tag{2.166}$$

累积分布函数 $F(x)$ 的意义是随机变量 t 小于或等于数值 x 的概率。使用这种表示方法，x 的期望可以写为：

---

① 随机变量的期望有时也被称为那个变量的平均值(mean)。在研究抽样时，这点很容易导致随机变量的期望值和样本的算术平均值之间的混淆。

$$E(x)=\int_{-\infty}^{+\infty} x\mathrm{d}F(x) \tag{2.167}$$

根据微积分基本定理，(2.167)式和(2.163)式等价。

例 2.15　一些随机变量的期望

前面介绍的四种分布的期望比较容易计算，图 2.6 已经标记出了这些分布的期望。

1. 二项分布

对于二项分布：

$$E(x)=1\cdot f(x=1)+0\cdot f(x=0)=1\cdot p+0\cdot(1-p)=p \tag{2.168}$$

考虑抛硬币这个例子($p=0.5$)，由上式可知，$E(x)=p=0.5$，与我们的直觉一致。

2. 均匀分布

对于连续随机变量：

$$E(x)=\int_a^b \frac{x}{b-a}\mathrm{d}x=\frac{x^2}{2(b-a)}\Big|_a^b=\frac{b^2}{2(b-a)}-\frac{a^2}{2(b-a)}=\frac{b+a}{2} \tag{2.169}$$

读者可能已经猜到这个结果——均匀分布的期望值是 a 和 b 的平均值。

3. 指数分布

指数分布的概率密度函数是减函数，其期望为：

$$E(x)=\int_0^{\infty} x\lambda \mathrm{e}^{-\lambda x}\mathrm{d}x=-x\mathrm{e}^{-\lambda x}-\frac{1}{\lambda}\mathrm{e}^{-\lambda x}\Big|_0^{\infty}=\frac{1}{\lambda} \tag{2.170}$$

这个积分使用了本章之前介绍过的分部积分法[(2.123)式]。注意，概率密度函数递减得越快，x 的期望越小。举个例子，如果 $\lambda=0.5$，则 $E(x)=2$，而如果 $\lambda=0.05$，则 $E(x)=20$。

4. 标准正态分布

标准正态分布的概率密度函数关于 y 轴对称，所以它的期望值应该等于 0。证明这个猜测需要使用换元法，令 $u=x^2/2$($\mathrm{d}u=x\mathrm{d}x$)：

$$\int_{-\infty}^{+\infty}\frac{1}{\sqrt{2\pi}}x\mathrm{e}^{-x^2/2}\mathrm{d}x=\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{+\infty}\mathrm{e}^{-u}\mathrm{d}u=\frac{1}{\sqrt{2\pi}}(-\mathrm{e}^{-x^2/2})\Big|_{-\infty}^{+\infty}=\frac{1}{\sqrt{2\pi}}(0-0)=0 \tag{2.171}$$

当然，其他非标准正态分布的期望都可以使用线性变化求得，如(2.165)式所示。

请回答：线性变化以一种可预测的方式改变随机变量的期望——如果 $y=ax+b$，那么 $E(y)=aE(x)+b$，对于这个变化[记为 $h(x)$]，有 $E[h(x)]=h[E(x)]$。如果变换的函数不是线性函数，而是任意的凹函数[记为 $g(x)$]，$g'>0$，$g''<0$，那么 $E[g(x)]$ 与 $g[E(x)]$ 有何异同？

提示：解决这个问题需要使用詹森不等式，这一不等式将会在第 7 章中详细介绍，读者也可以参看练习题 2.14。

2.12.6　方差和标准差

随机变量的期望反映随机变量的集中趋势。而随机变量的方差(variance)[记为 σ_x^2 或 $\mathrm{Var}(x)$]则反映随机变量的分散程度。具体来看，方差被定义为一个随机变量与其期望值“偏差平方的期望”，表述为：

$$\mathrm{Var}(x)=\sigma_x^2=E[(x-E(x))^2]=\int_{-\infty}^{+\infty}(x-E(x))^2f(x)\,\mathrm{d}x \tag{2.172}$$

方差“有代表性”地衡量了随机变量与中心值的偏差的平方，尽管有些不够精确。在计算中，我们对期望的偏差做了平方运算，这是由于偏差值可能为正也可能为负，通过平方可以将所有偏差对分散程度的影响计算在内。在上述计算完成后，可以对计算结果做平方的逆运算，使得计量单位与原始的随机变量的计量单位相同。方差的平方根被称为标准差，表示为 $\sigma_x(=\sqrt{\sigma_x^2})$。这一表达式的名称正好反映了它的意义：$\sigma_x$ 的确是随机变量与其期望值特有的(“标准的”)偏差。

当对一个随机变量做线性变化后，可以很容易地推导出变换后的方差和标准差。假定 $y=ax+b$，那么：

$$\sigma_y^2=\int_{-\infty}^{+\infty}[ax+b-E(ax+b)]^2f(x)\,\mathrm{d}x=\int_{-\infty}^{+\infty}a^2[x-E(x)]^2f(x)\,\mathrm{d}x=a^2\sigma_x^2 \tag{2.173}$$

因此，给随机变量加上一个常数不会改变其方差值，而随机变量乘上一个常数则会使其方差变为原来的常数平方倍。因此，如果随机变量乘上一个常数，则其标准差也为原来随机变量标准差的常数倍：$\sigma_{ax}=a\sigma_x$。

例2.16 简单随机变量的方差和标准差

了解四种基本随机分布的方差和标准差能够帮助我们学习经济学知识。

1. 二项分布

计算二项分布时需要使用方差定义的离散形式：

$$\begin{aligned}\sigma_x^2&=\sum_{i=1}^{n}(x_i-E(x))^2f(x_i)=(1-p)^2\cdot p+(0-p)^2(1-p)\\&=(1-p)(p-p^2+p^2)=p(1-p)\end{aligned} \tag{2.174}$$

因此，标准差 $\sigma_x=\sqrt{p(1-p)}$。这个结果给了我们一个提示，当 $p=0.5$ 时，二项分布的方差和标准差取得最大值，此时方差 $\sigma_x^2=0.25$，标准差 $\sigma_x=0.5$。因为 $p(1-p)$ 的函数图形是一个相对平稳的抛物线，所以 p 值在 $p=0.5$ 附近的微小变化不会在很大程度上改变方差值的大小。

2. 均匀分布

在计算均匀分布的方差后，我们发现了一个有趣的结果：

$$\begin{aligned}\sigma_x^2&=\int_a^b\left(x-\frac{a+b}{2}\right)^2\frac{1}{b-a}\mathrm{d}x=\left(x-\frac{a+b}{2}\right)^3\cdot\frac{1}{3(b-a)}\Bigg|_a^b\\&=\frac{1}{3(b-a)}\left[\frac{(b-a)^3}{8}-\frac{(a-b)^3}{8}\right]=\frac{(b-a)^2}{12}\end{aligned} \tag{2.175}$$

数字12很少在数学的应用中出现，此处是除计量橘子或甜甜圈的数量外鲜有的几个用到12的地方之一。

3. 指数分布

求解指数分布的方差的过程相对复杂，幸运的是结果很简单。对于指数分布，其方差 $\sigma_x^2=1/\lambda^2$，标准差 $\sigma_x=1/\lambda$。指数分布的期望值和标准差相等，故而指数分布又被称为“单参数分布”。

4. 标准正态分布

对于标准正态分布，求解方差的积分过程也很烦琐。不过与指数分布一样，结果很简单。标